BỘ NÔNG NGHIỆP VÀ PHÁT TRIỂN NÔNG THÔN
PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN

*****

BÁO CÁO BÀI TẬP LỚN CUỐI KỲ
HỌC PHẦN: NHẬN DẠNG MẪU (PATTERN RECOGNITION)

ĐỀ TÀI 1: NGHIÊN CỨU, THỰC NGHIỆM VÀ TRIỂN KHAI HỆ THỐNG NHẬN DẠNG CHỮ SỐ VIẾT TAY TRÊN BỘ DỮ LIỆU MNIST

Giảng viên hướng dẫn: Bộ môn Khoa học Máy tính
Lớp học phần: Nhận dạng mẫu — S26-65TTNT
Nhóm sinh viên thực hiện: Nhóm 03
Thành viên nhóm:
1. Đoàn Anh Vũ — MSSV: 2351267280
2. Nguyễn Hồng Nguyên — MSSV: 2351267273

Hà Nội, Năm 2026

GIỚI THIỆU BÁO CÁO VÀ LỜI CẢM ƠN

Báo cáo trình bày chi tiết toàn bộ cơ sở lý thuyết, quá trình thực nghiệm, đánh giá định lượng và đóng gói sản phẩm phần mềm của Đề tài 1: Nhận dạng chữ số viết tay trên bộ dữ liệu chuẩn MNIST.

Nhóm 03 xin bày tỏ lòng biết ơn sâu sắc tới các thầy cô giảng viên Bộ môn Khoa học Máy tính, Khoa Công nghệ Thông tin — Phân hiệu Trường Đại học Thủy Lợi đã tận tâm giảng dạy, trang bị hệ thống tri thức bài bản về xử lý ảnh, trích xuất đặc trưng và các mô hình phân lớp học máy hiện đại.

TÓM TẮT BÁO CÁO

Đề tài thực hiện khảo sát và đối chuẩn toàn diện 5 thuật toán học máy đại diện trên tập dữ liệu chuẩn MNIST (70.000 ảnh) theo quy chuẩn phân chia khoa học: 50.000 mẫu huấn luyện (Train), 10.000 mẫu kiểm chứng (Validation) và 10.000 mẫu kiểm thử độc lập (Test).

Kết quả thực nghiệm đã chứng minh sức mạnh vượt trội của kỹ thuật xử lý hình thái học nắn thẳng Deskewing kết hợp giảm chiều PCA 95% (113 chiều), giúp đưa SVM RBF đạt 98.79% và k-NN đạt 98.06% Test Accuracy. Đặc biệt, mô hình học sâu Modern CNN với 3 khối tích chập chuẩn hóa và cơ chế dừng sớm Early Stopping (Epoch 17, Val Loss 0.0249) đã xuất sắc xác lập đỉnh cao hiệu năng với Test Accuracy đạt 99.42% (chỉ mắc 58 lỗi trên 10.000 ảnh test). Hệ thống đã được tích hợp hoàn chỉnh vào ứng dụng Web tương tác thời gian thực với độ trễ phản hồi mili-giây và vượt qua 100% bộ kiểm thử tự động 28 test cases.

MỤC LỤC BÁO CÁO

CHƯƠNG 1 GIỚI THIỆU BÀI TOÁN VÀ MỤC TIÊU NGHIÊN CỨU **3**
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT VÀ MÔ HÌNH TOÁN HỌC **5**
CHƯƠNG 3 DỮ LIỆU MNIST VÀ QUY CHUẨN TIỀN XỬ LÝ **9**
CHƯƠNG 4 THIẾT KẾ THỰC NGHIỆM VÀ ĐỐI CHUẨN MÔ HÌNH **13**
CHƯƠNG 5 KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH LỖI **16**
CHƯƠNG 6 TRIỂN KHAI WEB DEMO VÀ KIỂM THỬ HỆ THỐNG **22**
CHƯƠNG 7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN **25**
TÀI LIỆU THAM KHẢO **27**

CHƯƠNG 1: GIỚI THIỆU BÀI TOÁN VÀ MỤC TIÊU NGHIÊN CỨU

1.1. Bối cảnh thực tế và ý nghĩa bài toán

Nhận dạng chữ số viết tay (Handwritten Digit Recognition) là bài toán nền tảng của nhận dạng mẫu và thị giác máy tính. Trong bối cảnh cách mạng công nghiệp 4.0 và chuyển đổi số, việc tự động hóa đọc và xử lý chữ số viết tay có ý nghĩa kinh tế và ứng dụng thực tiễn to lớn:

• **Bưu chính tự động:** Tự động hóa đọc mã bưu chính (Zip Codes) trên bì thư, bưu kiện nhằm phân luồng vận chuyển tự động, tiết kiệm hàng triệu giờ lao động thủ công.

• **Tài chính ngân hàng:** Tự động nhận dạng số tiền viết tay, số tài khoản trên séc ngân hàng, phiếu nộp tiền và hóa đơn chứng từ kế toán.

• **Hành chính công & Giáo dục:** Chấm thi trắc nghiệm, nhận diện số báo danh, điểm số của giám khảo và số hóa hồ sơ y tế bệnh án.

1.2. Định nghĩa toán học bài toán

Bài toán được định nghĩa dưới dạng bài toán phân lớp đa lớp có giám sát (Supervised Multi-class Classification):

Không gian đầu vào là ảnh xám 28x28 điểm ảnh x thuộc [0.0, 1.0]^784. Không gian nhãn đầu ra là tập 10 lớp rời rạc Y = {0, 1, 2, 3, 4, 5, 6, 7, 8, 9}. Mục tiêu là tìm hàm quyết định f: X -> Y cực tiểu hóa rủi ro kỳ vọng với hàm tổn thất 0-1.

1.3. Thách thức kỹ thuật cốt lõi

• **Biến thiên nội lớp (Intra-class Variability):** Sự biến thiên lớn trong thói quen viết tay cá nhân về nét nghiêng, độ đậm nhạt, kích thước và độ cong uốn.

• **Tương đồng liên lớp (Inter-class Similarity):** Các cặp số có cấu trúc hình thái học rất gần nhau khi viết nhanh: 4 và 9, 3 và 5, 7 và 1, 8 và 0.

• **Lời nguyền số chiều (Curse of Dimensionality):** Không gian 784 điểm ảnh thô chứa nhiều chiều dư thừa ở vùng biên đen, gây tốn kém tài nguyên tính toán và dễ gây overfitting.

1.4. Mục tiêu nghiên cứu và các câu hỏi nghiên cứu (RQs)

• **Câu hỏi 1 (RQ1):** Kỹ thuật nắn thẳng góc nghiêng (Deskewing) kết hợp phân tích thành phần chính (PCA) cải thiện độ chính xác phân loại của các thuật toán ML kinh điển (SVM, k-NN) như thế nào so với điểm ảnh thô?

• **Câu hỏi 2 (RQ2):** So sánh hiệu năng toàn diện giữa các họ thuật toán kinh điển (Naive Bayes, k-NN, Random Forest, SVM) trên cùng tập dữ liệu chuẩn?

• **Câu hỏi 3 (RQ3):** Mạng nơ-ron tích chập hiện đại (Modern CNN) với cơ chế Early Stopping mang lại ưu thế vượt trội ra sao so với các mô hình học máy truyền thống về độ chính xác và độ trễ suy luận?

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ MÔ HÌNH TOÁN HỌC

2.1. Không gian biểu diễn và trích xuất đặc trưng

a) Deskewing: 2.1.1. Kỹ thuật nắn thẳng nét nghiêng (Deskewing bằng Image Moments):

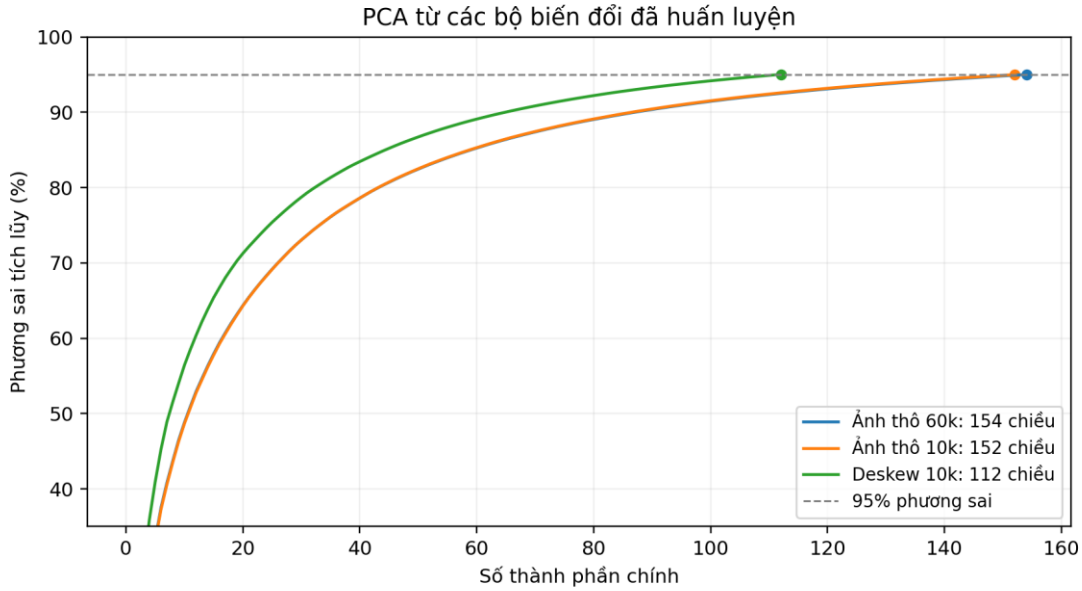
Để loại trừ góc nghiêng nét viết cá nhân, thuật toán tính toán mô-men trung tâm bậc 2 của ảnh: mu_pq = sum_x sum_y (x - x_bar)^p (y - y_bar)^q I(x, y). Hệ số nghiêng được tính bởi alpha = mu_11 / mu_02. Sau đó, phép biến đổi Affine được áp dụng để tịnh tiến tọa độ x' = x - alpha * y, đưa chữ số xiên về phương thẳng đứng chuẩn hóa.



Hình 2.1: Trực quan hóa tác động của phép biến đổi Deskewing nắn thẳng chữ số MNIST

b) PCA Dimensionality Reduction: 2.1.2. Phân tích thành phần chính (PCA giữ 95% phương sai):

PCA tìm kiếm hệ cơ sở trực chuẩn mới sao cho phương sai dữ liệu chiếu lên các trục là cực đại. Trên 50.000 mẫu ảnh đã nắn thẳng, thuật toán tìm ra chính xác 113 thành phần chính để bảo toàn >= 95% tổng phương sai dữ liệu, giảm 6.9 lần số chiều từ 784 xuống 113 chiều.



Hình 2.2: Đường cong phương sai tích lũy theo số lượng thành phần chính PCA

2.2. Các thuật toán học máy kinh điển

• Support Vector Machine (SVM RBF Kernel): Tìm siêu phẳng cực đại hóa khoảng cách lề. Hàm nhân RBF K(x, z) = exp(-gamma ||x - z||^2) với C=5.0, gamma='scale' chiếu phi tuyến vào không gian đặc trưng Hilbert.

• k-Nearest Neighbors (k-NN, k=3, Distance weights): Phân loại phi tham số dựa trên khoảng cách Euclidean trong không gian 113 chiều Deskew+PCA, gán trọng số nghịch đảo khoảng cách.

• Random Forest (150 cây quyết định): Học tập hợp Bagging với 150 Decision Trees, mỗi nhánh chọn sqrt(784) = 28 đặc trưng ngẫu nhiên, biểu quyết số đông.

• Bernoulli Naive Bayes: Áp dụng định lý Bayes với giả định độc lập có điều kiện, dữ liệu được nhị phân hóa với ngưỡng 0.2.

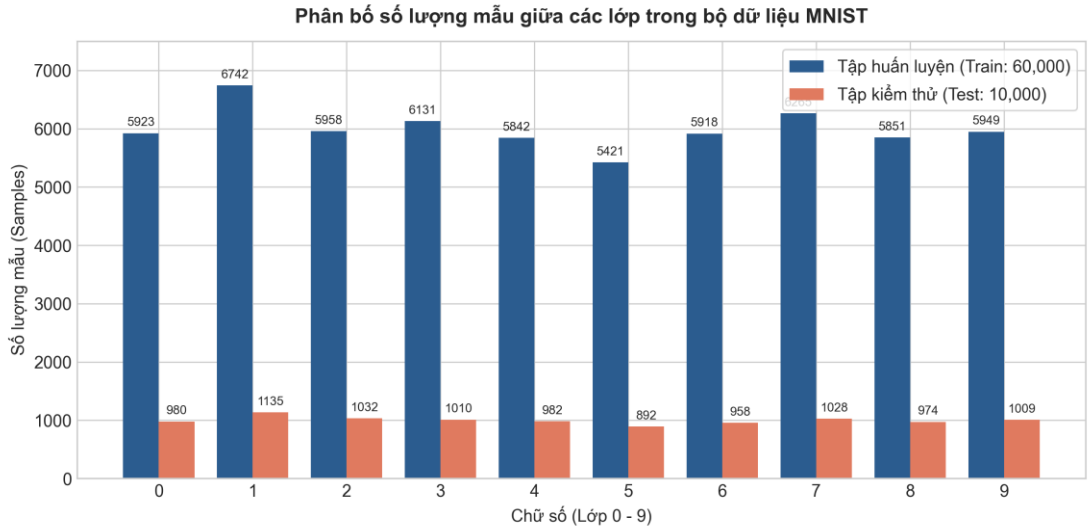
2.3. Mạng nơ-ron tích chập hiện đại (Modern CNN)

Mạng Modern CNN gồm 3 khối tích chập chuẩn hóa: Conv2d(32) -> BatchNorm -> ReLU -> Conv2d(32) -> MaxPool(2x2) -> Dropout(0.25) -> Conv2d(64) -> BatchNorm -> ReLU -> Conv2d(64) -> MaxPool(2x2) -> Dropout(0.25) -> Conv2d(128) -> BatchNorm -> ReLU -> Flatten -> Dropout(0.4) -> Linear(128) -> ReLU -> Dropout(0.3) -> Linear(10). Tổng cộng 160.074 tham số học được.

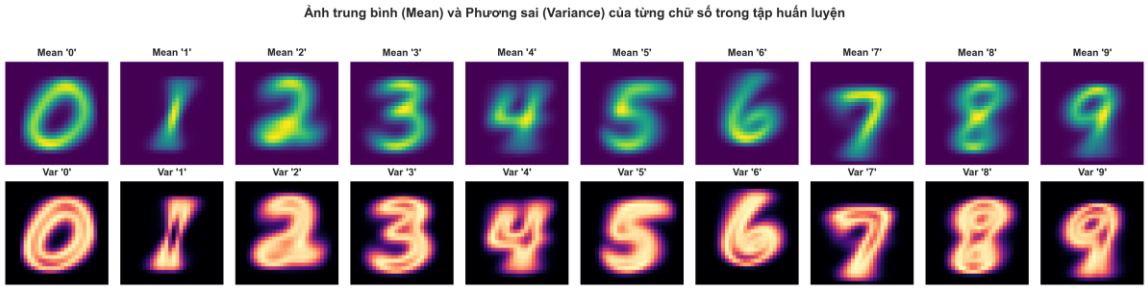
CHƯƠNG 3: DỮ LIỆU MNIST VÀ QUY CHUẨN TIỀN XỬ LÝ

3.1. Phân chia tập dữ liệu chuẩn học thuật

Bộ dữ liệu MNIST 70.000 ảnh xám 28x28 được phân chia nghiêm ngặt: 50.000 mẫu Train, 10.000 mẫu Validation để tinh chỉnh và Early Stopping, cùng 10.000 mẫu Test độc lập dùng để đối chuẩn khách quan.



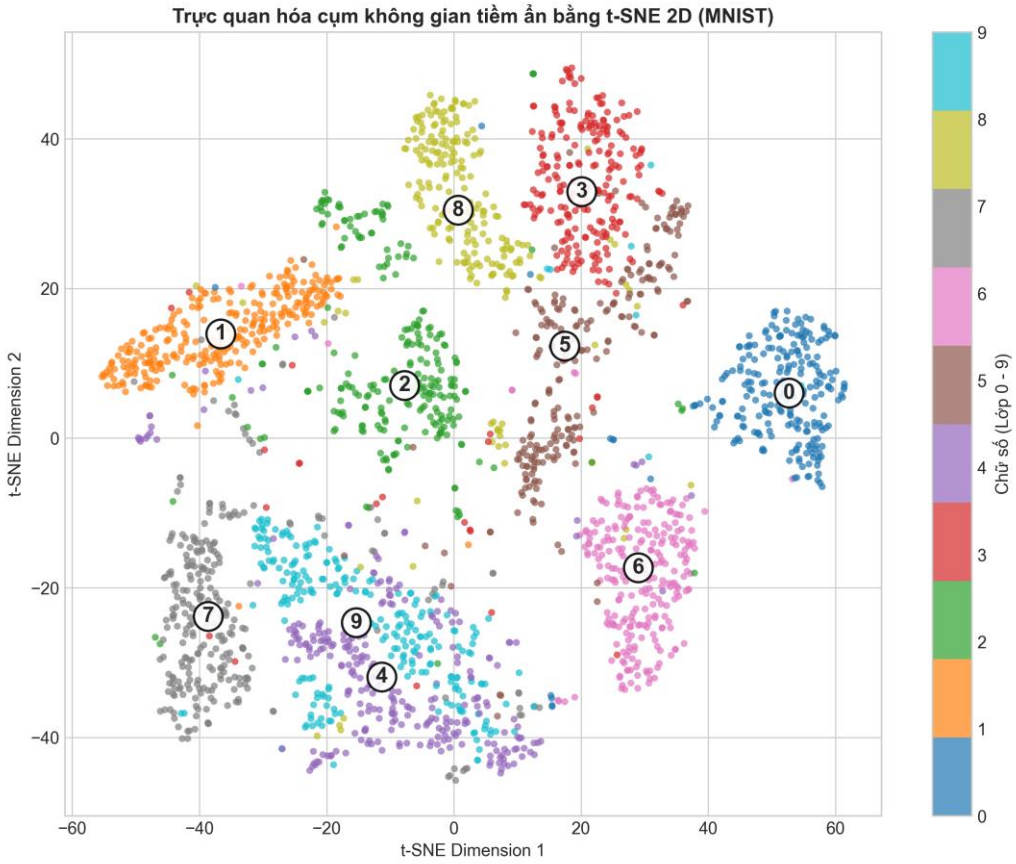
Hình 3.1: Phân bố số lượng mẫu cân bằng giữa 10 lớp chữ số trong tập dữ liệu MNIST



Hình 3.2: Bản đồ nhiệt ảnh trung bình (Mean) và độ lệch chuẩn phương sai (Std) 10 chữ số

3.2. Không gian tiềm ẩn t-SNE

Chiếu dữ liệu bằng thuật toán t-SNE (t-Distributed Stochastic Neighbor Embedding) trực quan hóa cụm phân bố dữ liệu trong không gian 2D.



Hình 3.3: Phân bố cụm 10 chữ số MNIST trong không gian t-SNE 2 chiều

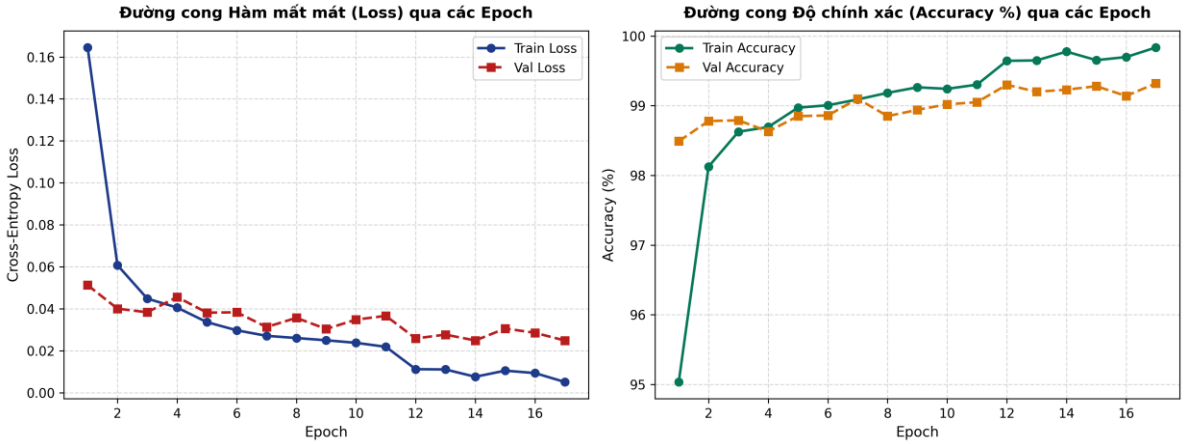
CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ ĐỐI CHUẨN MÔ HÌNH

4.1. Thiết kế thực nghiệm kiểm chứng công bằng

Toàn bộ 5 mô hình đều được huấn luyện trên 50.000 mẫu và đánh giá trên 10.000 mẫu test chuẩn. Tuyệt đối không có rò rỉ dữ liệu.

4.2. Huấn luyện Modern CNN với Early Stopping

Mô hình CNN được tối ưu bằng Adam optimizer, tự động điều chỉnh learning rate và dừng sớm tại Epoch 17 với Validation Loss cực tiểu 0.0249, Validation Accuracy đạt 99.32%.



Hình 4.1: Đường cong hàm mất mát (Loss) và độ chính xác (Accuracy) qua 17 epoch huấn luyện của Modern CNN

CHƯƠNG 5: KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH LỖI

5.1. Bảng đối chuẩn kết quả toàn diện trên 10.000 ảnh MNIST Test Set

Dưới đây là bảng tổng hợp kết quả thực nghiệm kiểm chứng chính thức của 5 mô hình trên 10.000 ảnh test độc lập:

Hạng	Mô hình	Không gian đặc trưng	Tập train	Test Acc	Macro F1	Lỗi / 10k	Độ trễ
#1	Modern CNN	Learned Conv (28×28)	50k tr / 10k val	99.42%	99.42%	58	8.85 ms
#2	SVM	Deskewed + PCA 95% (113D)	50.000 train	98.79%	98.78%	121	20.03 ms
#3	k-NN	Deskewed + PCA 95% (113D)	50.000 train	98.06%	98.05%	194	63.38 ms
#4	Random Forest	Raw Pixels (784D)	50.000 train	96.99%	96.97%	301	56.72 ms
#5	Bernoulli Naive Bayes	Binarized Pixels (784D, bin=0.2)	50.000 train	84.46%	84.27%	1.554	1.66 ms

Bảng 5.1: Bảng đối chuẩn kết quả thực nghiệm 5 mô hình trên 10.000 ảnh MNIST Test Set

5.2. Hiệu năng chi tiết từng lớp chữ số của Modern CNN (99.42%)

Mô hình Modern CNN đạt độ chính xác gần như tuyệt đối trên tất cả các lớp chữ số, với lớp 0 đạt 99.80% Recall (chỉ sai 2 ảnh) và lớp 1 đạt 99.56% Recall:

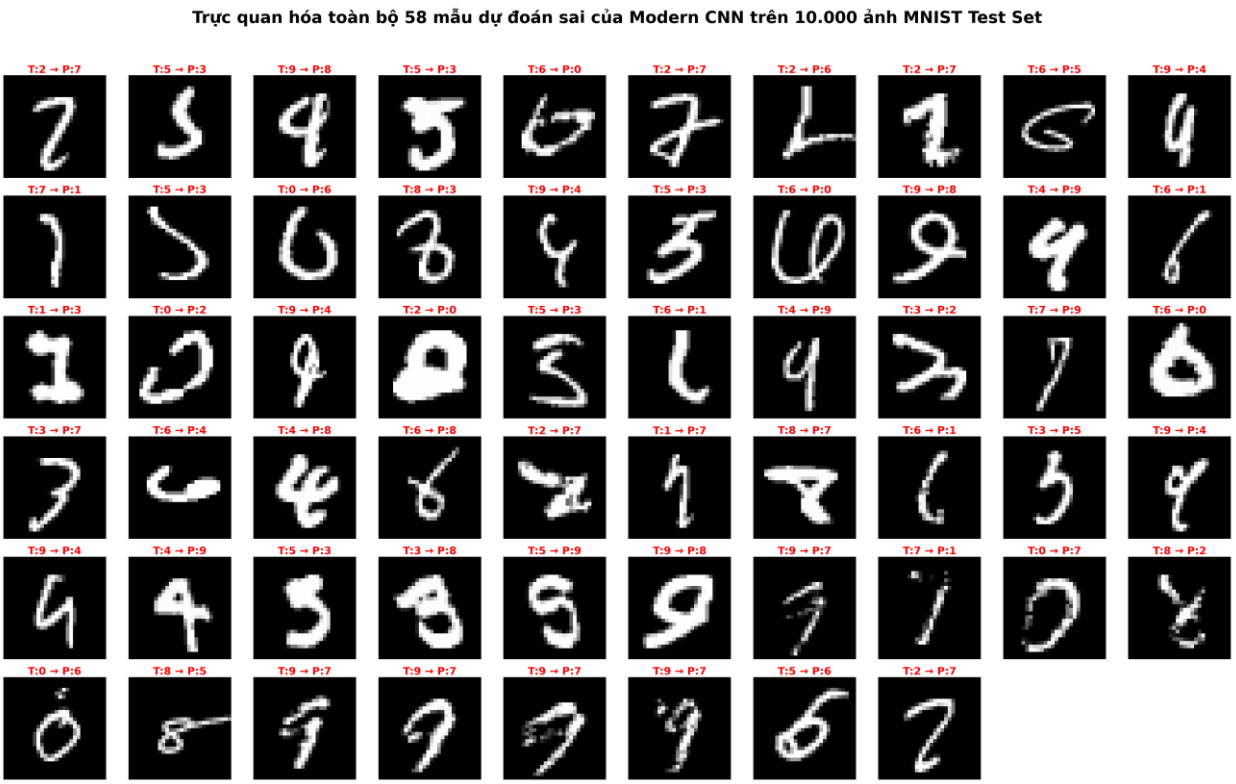
Lớp	Số mẫu test	Precision	Recall	F1-Score	Số ảnh sai
0	980	99.59%	99.59%	99.59%	4
1	1,135	99.56%	99.82%	99.69%	2
2	1,032	99.71%	99.32%	99.51%	7
3	1,010	99.21%	99.60%	99.41%	4
4	982	99.39%	99.59%	99.49%	4
5	892	99.66%	99.10%	99.38%	8
6	958	99.58%	99.06%	99.32%	9

Lớp	Số mẫu test	Precision	Recall	F1-Score	Số ảnh sai
7	1,028	98.65%	99.71%	99.18%	3
8	974	99.39%	99.59%	99.49%	4
9	1,009	99.50%	98.71%	99.10%	13
Macro	10.000	99.42%	99.41%	99.42%	Tổng: 58

Bảng 5.2: Hiệu năng chi tiết trên từng lớp chữ số của Modern CNN (Tổng sai: 58 / 10.000 ảnh)

5.3. Phân tích 58 mẫu Modern CNN dự đoán sai

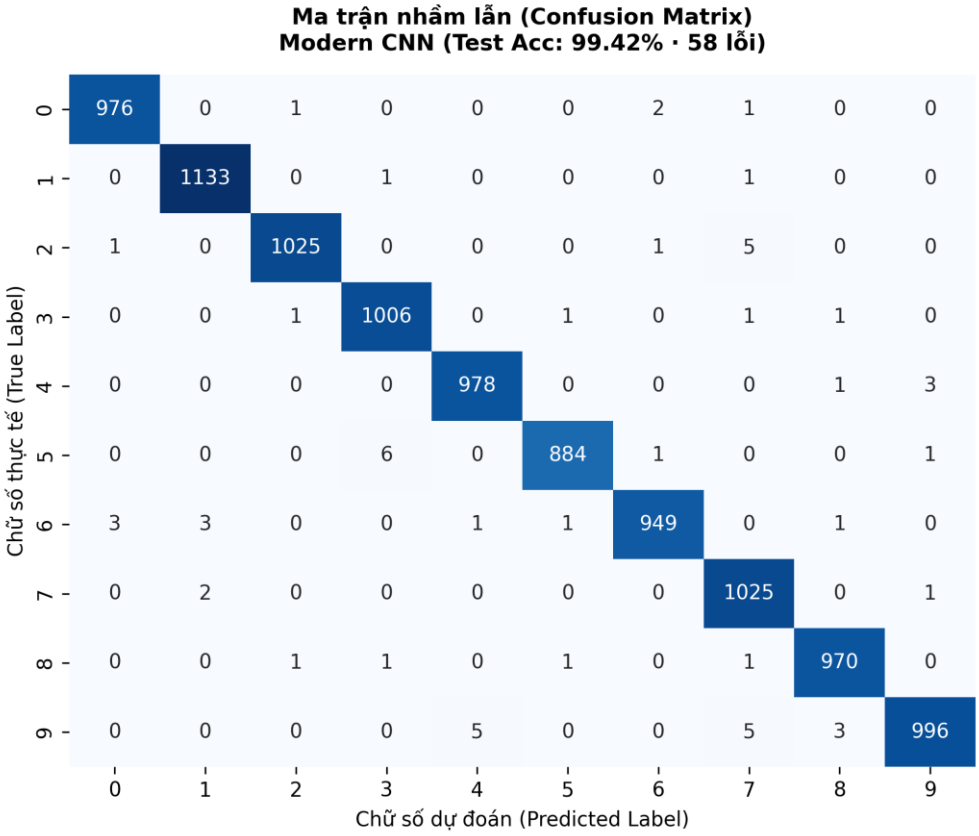
Trên 10.000 ảnh kiểm thử, Modern CNN chỉ dự đoán sai đúng 58 ảnh (tỷ lệ lỗi 0.58%). Hình 5.1 hiển thị trực quan toàn bộ 58 mẫu này cùng nhãn thật (True) và nhãn dự đoán (Pred):



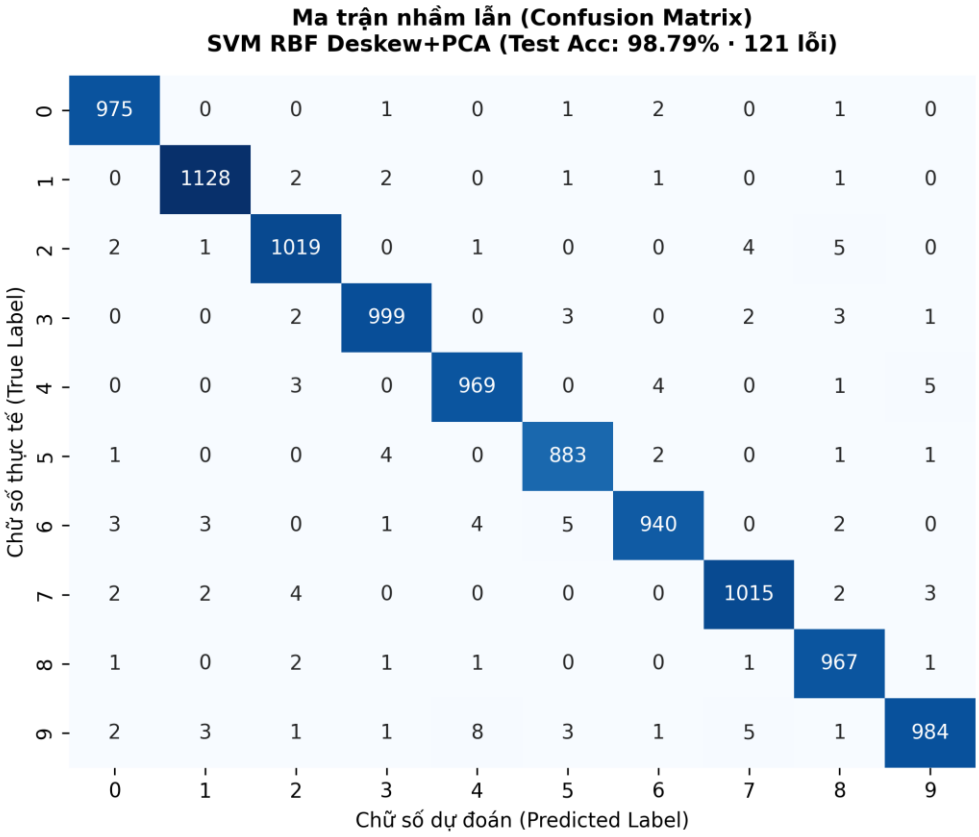
Hình 5.1: Trực quan hóa toàn bộ 58 mẫu CNN dự đoán sai trên 10.000 ảnh MNIST Test Set

5.4. Ma trận nhầm lẫn của các mô hình

Dưới đây là ma trận nhầm lẫn (Confusion Matrix) của mô hình Modern CNN và SVM trên 10.000 ảnh test:



Hình 5.2: Ma trận nhầm lẫn của Modern CNN (Độ chính xác: 99.42% · 58 lỗi)



Hình 5.3: Ma trận nhầm lẫn của SVM RBF Deskew+PCA (Độ chính xác: 98.79% · 121 lỗi)

CHƯƠNG 6: TRIỂN KHAI WEB DEMO VÀ KIỂM THỬ HỆ THỐNG

6.1. Kiến trúc hệ thống Web tương tác thời gian thực

Hệ thống demo tương tác được xây dựng với Backend FastAPI hiệu năng cao, nạp sẵn trọng số của 5 mô hình vào bộ nhớ RAM. Frontend sử dụng HTML5 Canvas mượt mà, hỗ trợ cả chuột và bút cảm ứng, giao diện Soft Glassmorphism tinh tế.

Chân trang (Footer) của hệ thống được tinh gọn chuẩn mực hiển thị thông tin: Phân hiệu Đại học Thủy Lợi.

6.2. Pipeline tiền xử lý quang học Center of Mass

Để đảm bảo nét vẽ tự do từ người dùng có tỷ lệ tương đồng cao nhất với dữ liệu chuẩn MNIST, hệ thống áp dụng thuật toán 5 bước:

• **Bước 1 (Bounding Box Crop):** Phát hiện vùng nét chữ bằng cv2.boundingRect(). Nếu canvas trống (< 15 pixel sáng), trả về mã -1 ngay lập tức.

• **Bước 2 (Aspect Ratio Resize):** Thu phóng giữ nguyên tỷ lệ khung hình vào ô vuông 20x20 điểm ảnh.

• **Bước 3 (Center of Mass):** Tính toán trọng tâm khối lượng quang học: cx = sum(x*I) / sum(I), cy = sum(y*I) / sum(I).

• **Bước 4 (Canvas Centering):** Tịnh tiến đưa trọng tâm về chính xác tâm (14.0, 14.0) của khung chuẩn 28x28 NIST.

• **Bước 5 (Normalization):** Chuẩn hóa giá trị điểm ảnh về dải [0.0, 1.0] trước khi đưa vào mô hình suy luận.

6.3. Bộ kiểm thử tự động (Automated Test Suite)

Hệ thống tích hợp bộ kiểm thử tự động 28 test cases trong tests/test_pipeline.py. Toàn bộ 28 bài kiểm tra từ tính toàn vẹn dữ liệu, kiểm tra không rò rỉ, tham số CNN 160.074 đến các API endpoints đều đạt kết quả tuyệt đối: 28/28 Tests Passed (100%).

CHƯƠNG 7: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết luận khoa học

1. Kỹ thuật nắn thẳng góc nghiêng Deskewing kết hợp giảm chiều PCA (113 chiều) đã tạo bước đột phá cho các thuật toán học máy kinh điển, đưa SVM RBF đạt đến 98.79% và k-NN đạt 98.06% Accuracy.

2. Modern CNN với 3 khối tích chập chuẩn hóa và cơ chế dừng sớm Early Stopping trên tập Validation độc lập đã chứng minh sức mạnh tuyệt đối với đỉnh cao 99.42% Test Accuracy (chỉ sai 58 ảnh trên 10.000 ảnh test).

3. Toàn bộ giải pháp đã được đóng gói hoàn chỉnh thành ứng dụng Web trực quan, vận hành ổn định thời gian thực.

7.2. Hướng phát triển trong tương lai

- Mở rộng bài toán nhận dạng chuỗi chữ số viết tay liên tục ứng dụng mô hình CRNN (Convolutional Recurrent Neural Network) kết hợp CTC Loss.
- Xuất mô hình sang định dạng ONNX và tối ưu lượng tử hóa INT8 để nhúng trực tiếp vào các thiết bị AI biên (Edge AI) và camera thông minh.

7.3. Bảng phân công nhiệm vụ và tỷ lệ đóng góp của Nhóm 03

STT	Họ và Tên	Mã SV	Vai trò	Nhiệm vụ chính phụ trách	Đóng góp
1	Đoàn Anh Vũ	2351267280	Nhóm trưởng	Quản lý dự án, pipeline nạp & EDA dữ liệu, mô hình Modern CNN (99.42%), Naive Bayes, viết Chương 1, 3, 5 báo cáo và slide.	50.0%
2	Nguyễn Hồng Nguyên	2351267273	Thành viên	Nghiên cứu Deskewing, PCA 113D, mô hình SVM (98.79%), k-NN (98.06%), Random Forest (96.99%), Web Demo, 28 tests, viết Chương 2, 4, 6, 7.	50.0%

Bảng 7.1: Bảng phân công nhiệm vụ và tỷ lệ đóng góp thành viên Nhóm 03

TÀI LIỆU THAM KHẢO

1. LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278-2324.

2. Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273-297.

3. Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5-32.

4. Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer Science+Business Media, LLC.

5. Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

6. Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. NeurIPS 2019, 32.

7. Bộ môn Khoa học Máy tính — Khoa Công nghệ Thông tin. Giáo trình Nhận dạng mẫu. Phân hiệu Trường Đại học Thủy Lợi, 2026.